BÁO CÁO CUỐI KỲ

Kho dữ liệu và khai phá dữ liệu bán hàng

Xoaif Garden · Pancake POS · DuckDB

Tổ chức dữ liệu theo thời gian; kiểm toán quy tắc tiền; đánh giá mô hình, phân khúc và luật kết hợp.

DEV	TEST	COMBO
6.400 đơn status 3	5.169 khách đủ điều kiện	24 luật đóng băng trước test

Cửa sổ test: [2025-10-22, 2026-04-20) · mở đúng một lần

26/10/2026

Mục lục

Cấu trúc theo bài toán, kho dữ liệu và ba hướng khai phá

03 Giới thiệu, bối cảnh và câu hỏi kinh doanh

04 Kiến trúc tổng quan 5 tầng và công cụ

05 Dữ liệu, ETL và Star Schema

06 Chất lượng dữ liệu và kiểm toán tiền

07 EDA và hệ quả cho tiền xử lý

08 Tiền xử lý, quà tặng theo dòng và chống rò rỉ

09 Học có giám sát trên DEV

10 Đánh giá test đã khóa một lần

11 Phân khúc khách hàng

12 Luật kết hợp, combo và mùa vụ

13 Kết luận và giới hạn

14 Hướng dẫn chạy lại, file bàn giao và thuật ngữ

15 Nhật ký quyết định và phụ lục

1. Giới thiệu

Cửa hàng mở 04/2024; dữ liệu trước đó được giữ trong raw như giai đoạn bán thử

Bối cảnh

Dự án khai thác dữ liệu bán hàng từ Pancake POS nhằm phục vụ học phần Kho và Khai phá dữ liệu. Chủ dự án xác nhận cửa hàng bắt đầu hoạt động ngày 2024-04-01. Snapshot còn có 476 đơn giai đoạn bán thử từ 2022-06 đến 2022-09; các đơn này không tham gia doanh thu phân tích, hành vi khách, nhãn hay giỏ hàng.

Ba câu hỏi kinh doanh

1. Khách hàng nào có hành vi giá trị hoặc mua lặp lại theo lịch sử quan sát?
2. Có đủ bằng chứng để xếp hạng khả năng mua lại trong cửa sổ thời gian kế tiếp không?
3. Những sản phẩm nào đồng xuất hiện trong một giỏ đủ điều kiện, sau khi xử lý quà theo từng dòng?

Phạm vi và ngôn ngữ báo cáo

Khoảng phát triển hiệu dụng bắt đầu 2024-04-01 và kết thúc trước mốc T = 2025-10-22. Dùng thuật ngữ “doanh thu ghi nhận” theo quy tắc nghiệp vụ status 3; không gọi là lợi nhuận hoặc đối soát ngân hàng. Luật kết hợp chỉ mô tả đồng xuất hiện, không khẳng định quan hệ nhân quả.

2. Kiến trúc tổng quan

Hình 1. Luồng 5 tầng từ nguồn tới sản phẩm phân tích

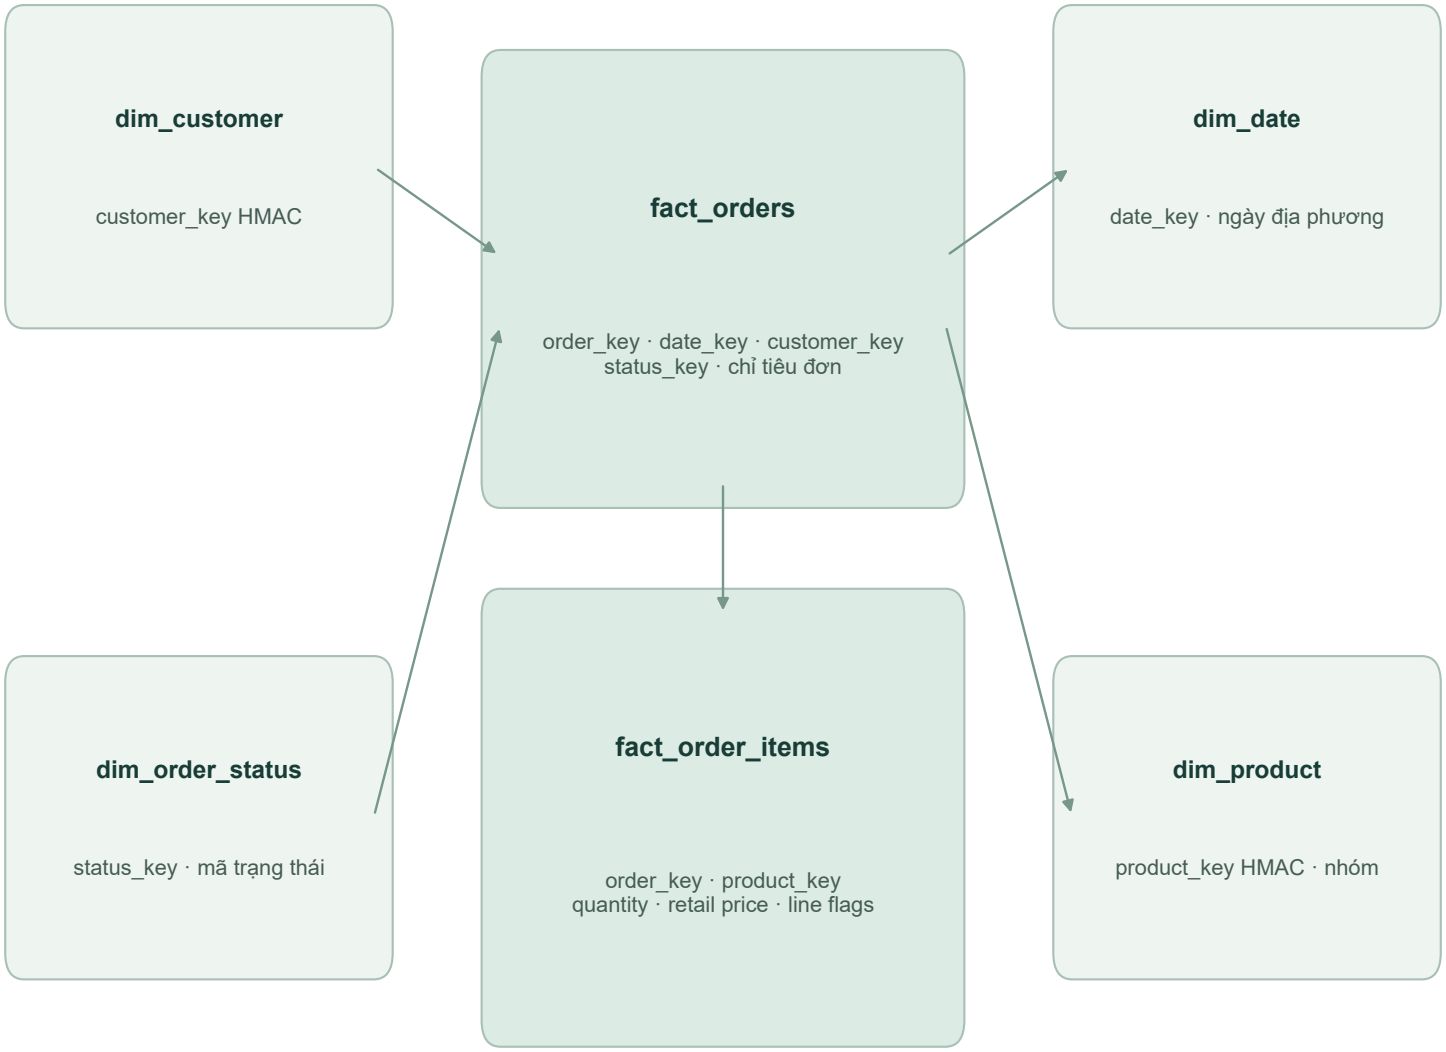


Luồng truy vấn nguồn chỉ GET. Dashboard đọc snapshot tổng hợp cục bộ và không có thao tác ghi API.

Vai trò: API lấy dữ liệu · checksum chứng minh bản chụp · ETL chuẩn hóa · DuckDB truy vấn · Python/Streamlit trình bày.

3. Dữ liệu và kho Star Schema

Hình 2. Mô hình logic: sự kiện ở fact, ngữ cảnh ở dimension



Kho phát triển gồm fact_orders, fact_order_items, dim_customer, dim_date, dim_order_status và dim_product. Khóa khách và sản phẩm được HMAC; kho không chứa địa chỉ, văn bản tự do, lịch sử trạng thái hay trường tiền. Chỉ tiêu tiền được giữ trong các đầu ra tổng hợp kiểm toán riêng.

ETL giữ grain đơn hàng và dòng hàng tách biệt; khóa ngày dùng ngày địa phương Asia/Ho_Chi_Minh.

4. Chất lượng dữ liệu và kiểm toán tiền

Bảng 1. Kiểm tra trên DEV status 3 theo quy tắc tiền Amendment 03

Chỉ tiêu	Giá trị
Đơn status 3 DEV	6.400
Đơn quà cấp đơn loại	22
Đơn doanh thu âm	2 (0,03%)
price_adjustment dương / âm	651 / 8
Tổng price_adjustment ròng	52.016.532 đ
Ròng / doanh thu ghi nhận	1,98%
Lệch không giải thích hết	639 (9,98%)

Định nghĩa và diễn giải

Doanh thu ghi nhận dùng total_price_after_sub_discount - shipping_fee; khi trường sau giảm bằng total_price - total_discount và phí giao hàng dương, giữ giá sau giảm để tránh trừ phí hai lần. price_adjustment = doanh thu ghi nhận - (total_price - total_discount). Điều chỉnh có thể phản ánh phí hoặc ưu đãi; không được hiểu là lợi nhuận.

Độ nhạy A/B

Công thức A làm tổng doanh thu lệch 52.016.532 đ, bằng 2,02% tổng A; 642/6.378 đơn lệch trên 1%. Tương quan Spearman giữa Monetary theo khách là 0,9953. Độ nhạy cho biết kết quả phân khúc bền với phép đo này; không chứng minh công thức A hay B đúng.

5. EDA và hệ quả cho xử lý

Hình 3. Doanh thu ghi nhận theo tháng từ bảng tổng hợp; không phân bổ xuống sản phẩm



Đường gạch là mốc bắt đầu test; tháng cuối chưa trọn tháng.

Không so sánh doanh thu theo tỉnh/thành: UNKNOWN chiếm 91,92% tổng doanh thu (8.403 đơn); nguyên nhân chưa phân tích.

Snapshot có 247 tên mặt hàng quan sát ở bảng sản phẩm; product_profile.csv mô tả support, quà theo dòng, ngày đầu/cuối và tháng bán. Tên sản phẩm không được dùng để xác định quà. 476 đơn bán thử 2022 được giữ riêng. Do chiết khấu và điều chỉnh ở cấp đơn, báo cáo chỉ nêu số đơn/dòng theo sản phẩm, không gán doanh thu ghi nhận cho sản phẩm.

Nguồn số liệu: outputs/tables/dashboard_sales_monthly.csv, dashboard_sales_province.csv, dashboard_product_orders.csv.

6. Tiền xử lý và chống rò rỉ

Bảng 2. Nhận diện gift line theo dữ liệu, không theo danh sách tên

Nguồn phân loại	Số dòng DEV
flag API đã xác minh	0
Giá thực bằng 0 / giảm 100%	4
Suy luận subset sum duy nhất	903 · độ tin cậy thấp
Không phải quà	29142
Tổng	30049

Trường is_bonus_product có mặt ở toàn bộ 30.049 dòng nhưng không bật; vì vậy không sinh nhãn flag. Quy tắc 0-price/giảm 100% được áp trước subset sum. Suy luận subset xét tối đa 6 dòng và chỉ nhận khi có đúng một tập con khớp total_discount. Không dùng tên, giá thấp hay support.

Quy mô: 6.400 đơn status 3; 22 đơn quà cấp đơn bị loại; 6.031 giỏ trước và 6.006 sau loại dòng quà; 726 dòng thiếu product_id. Ngưỡng đơn lớn là phân vị 90 DEV = 700.000 đ.

Split thời gian: DEV trước T=2025-10-22; test [2025-10-22, 2026-04-20). Hash split/config được lưu ở config/split.lock.json và amendment 05. Nhật ký tiền kiểm ghi 2 lần eligibility_count, không có truy vấn đọc nhãn hay hành vi test trước khi khóa mở. Huỷ/hoàn không fit: fold dương 30/13/6/1/18, có fold dưới 20 mẫu.

7. Học có giám sát trên DEV

Bảng 3. So sánh OOF theo 5 fold thời gian; ngưỡng 0,5

Mô hình	Cấu hình khóa	ROC-AUC	AP/PR-AUC	F1
Baseline	—	0,536	0,067	0,000
Logistic Regression C=10 (chính, D-005)	C=10	0,510	0,070	0,104
Logistic Regression feature-v2	C=0,1	0,497	0,065	0,097
Decision Tree	max_depth=4	0,538	0,080	0,112
Random Forest	depth=16; leaf=5	0,534	0,075	0,047

Vòng DEV feature-v2 bổ sung có 3.508 khách trong tập nhãn, 260 dương (7,4%). Ứng viên Logistic Regression feature-v2 có C=0,1 được chọn trong vòng bổ sung theo PR-AUC trung bình 5 fold. OOF pooled: ROC-AUC 0,4969, AP 0,0645; CI 95% ROC [0,4330; 0,5599], CI AP [0,0490; 0,0914].

Mô hình chính vẫn là Logistic Regression C=10 theo D-005; v2 C=0,1 là khảo sát bổ sung, không thay vai trò mô hình chính. DEV OOF ROC-AUC C=10 là 0,5096, gần mức ngẫu nhiên; feature-v2 là 0,4969. DEV chưa xác nhận tín hiệu xếp hạng rõ. Mọi preprocessing chỉ fit trong train fold; test không dùng để chọn cấu hình.

8. Đánh giá test một lần

Bảng 4. Mô hình và ngưỡng đã đóng băng; không fit hoặc chọn lại

Mô hình	Prec	Recall	F1	ROC	AP	TN/FP/FN/TP
Baseline	0,000	0,000	0,000	0,500	0,046	4.932/0/237/0
C=10 — mô hình chính	0,167	0,333	0,223	0,702	0,123	4.538/394/158/79
feature-v2 C=0,1 — bổ sung	0,152	0,350	0,212	0,703	0,123	4.468/464/154/83

Cohort 5.169 khách, 237 dương; prevalence DEV/test 7,4%/4,6%. Logistic Regression C=10 — mô hình chính theo D-005: ROC-AUC 0,7024 (CI 0,6651–0,7365), AP 0,1234 (CI 0,1005–0,1581), ΔAP +0,0776 (CI +0,0560–+0,1109).

Logistic Regression feature-v2 C=0,1 — khảo sát bổ sung theo Amendment 04; không thay mô hình chính: ROC-AUC 0,7027 (CI 0,6651–0,7373), AP 0,1233 (CI 0,0994–0,1582), ΔAP +0,0774 (CI +0,0554–+0,1111). Bootstrap paired theo khách, 2.000 lượt; ngưỡng phân loại 0,5.

Ngưỡng tín hiệu được ghi cho các classifier trong Amendment 05: cận dưới CI ROC-AUC > 0,55 và cận dưới CI ΔAP > 0; các CI aggregate của cả hai cấu hình thỏa các cận trong lần chạy thực tế. Vượt ngưỡng về mặt số liệu không xác nhận tuân thủ giao thức do sai khác ngày T.

DEV OOF ROC-AUC C=10 là 0,5096, gần mức ngẫu nhiên; ROC-AUC test 0,7024 chỉ là tín hiệu yếu chưa được DEV xác nhận. Không kết luận mô hình hoạt động tốt. Test đã mở; không dùng kết quả này để tinh chỉnh hoặc chọn lại mô hình. Cấu hình ghi >T, evaluator dùng [T,end) (gồm ngày T); ảnh hưởng chưa xác định; đây là kết quả số liệu của lần chạy thực tế, không phải khẳng định tuân thủ đầy đủ giao thức, không gọi là 'đạt cổng ghi trước'.

9. Học không giám sát: phân khúc

Bảng 5. K-Means và quy tắc nghiệp vụ được đọc song song

K-means	Khách scoring (5.16	Tỷ trọng	Doanh thu trước T	Doanh thu test	F TB	Monetary TB
0	4523	87,5%	1.674.204.729 đ	101.174.400 đ	1,00	370.154 đ
1	646	12,5%	873.254.612 đ	78.411.448 đ	2,42	1.351.787 đ

Bảng dùng cohort scoring: 4.530/5.169 khách (87,6%) có một đơn; DEV status 3 là 4.526/5.174 (87,5%). K=2 được chọn, silhouette=0,508. Quy tắc nghiệp vụ có 5.169 khách; proxy giá trị lớn có 62 khách theo ngưỡng p99, không xác minh pháp nhân.

K=2 chủ yếu chia khách mua một lần với khách mua lặp lại; đây là khác biệt tần suất mô tả được, chưa chứng minh hai nhóm có ý nghĩa kinh doanh hay giúp ra quyết định tốt hơn. Không fit lại trên test: frozen segmenter được áp lên cùng hồ sơ trước T. Khoảng cách phân phối bằng 0 vì vậy không chứng minh hành vi tương lai ổn định. Doanh thu test chỉ báo riêng, không cập nhật tâm cụm.

10. Luật kết hợp và combo

Bảng 6. Chỉ giữ luật đã đóng băng trước test

Cặp sản phẩm	Support DEV	Support test	Lift DEV	Lift test
PORTCARD HƯỚNG DẪN CHĂM CÂY + TÚI GIẤY XOA…	39,9%	15,2%	1,32	2,48
PORTCARD HƯỚNG DẪN CHĂM CÂY + CHẬU TRỤ	15,4%	13,2%	0,95	1,21
ĐÔ LA NGỌC BÍCH + CHẬU TRỤ	5,8%	10,2%	1,74	2,56
PORTCARD HƯỚNG DẪN CHĂM CÂY + CẨM NHUNG	16,3%	9,5%	1,01	0,96
CHẬU TRỤ + CẨM NHUNG	7,1%	7,9%	1,28	1,07
ĐÔ LA NGỌC BÍCH + PORTCARD HƯỚNG DẪN CHĂM …	9,5%	6,6%	0,98	1,23
TÚI GIẤY XOAIF GARDEN + CHẬU TRỤ	10,0%	6,1%	0,96	1,33
PHỤ KIỆN BẢNG TÊN + PORTCARD HƯỚNG DẪN CHĂ…	13,9%	5,4%	1,02	1,04

Phân tích giỏ: 6.031 trước và 6.006 sau loại quà. So sánh nhạy cảm gồm mọi dòng; chỉ loại flag/zero_price; và loại mọi nguồn quà, tại min_support 0,01 và 0,05. 24 cặp chính ổn định ở ít nhất 4/6 ô; 21/24 cặp frozen có lift > 1 trong test. Test có 2.174 giỏ đủ điều kiện; không chọn luật mới.

Support mùa vụ tính trong tháng chồng lấp của mỗi cặp; nhãn mùa chỉ gắn khi quan sát tập trung quanh ngày lễ theo cửa sổ đã đăng ký. DEV có một mùa Tết trọn vẹn, chưa đủ để suy ra chu kỳ năm. Giá niêm yết gộp là mô tả; không có giá vốn, không phân bổ chiết khấu, không suy ra hiệu quả lợi nhuận. Association = đồng xuất hiện, không phải nhân quả.

Nguồn đầy đủ: outputs/tables/combos_v2.csv, seasonal_pair_metrics.csv, test_combos_frozen.csv.

11. Kết luận và giới hạn

Kết quả học thuật cần được đọc cùng điều kiện dữ liệu

Kết luận

Quy trình tạo kho Star Schema và kiểm toán nghiệp vụ có split thời gian, hash và nhật ký amendment. K=2 chủ yếu tách khách mua một lần và khách mua lặp lại, chưa chứng minh ý nghĩa kinh doanh. 24 combo chính được khóa theo quy tắc ít nhất 4/6 ô. ROC-AUC DEV OOF C=10 là 0,5096, gần ngẫu nhiên; ROC-AUC test 0,7024 là tín hiệu yếu chưa được DEV xác nhận, không đủ để kết luận mô hình hoạt động tốt. Test đã mở; không tinh chỉnh theo kết quả test. Cấu hình ghi >T, evaluator dùng [T,end) (gồm ngày T); ảnh hưởng chưa xác định. Xem docs/test_provenance_note.md.

Hạn chế

- Khoảng hiệu dụng khoảng 18 tháng và chỉ có một Tết trọn vẹn trong DEV.
- 91,92% doanh thu theo tỉnh/thành mang nhãn UNKNOWN; không so sánh địa lý.
- Thiếu dữ liệu phản hồi có nhãn; không thực hiện bài phân loại phản hồi.
- 903 dòng inferred_subset là suy luận có thể gán nhầm; cờ API không bật.
- Không có giá vốn nên không thể kết luận lợi nhuận combo.
- Status hiện tại không phải lịch sử trạng thái; doanh thu ghi nhận theo xác nhận nghiệp vụ.
- Một cửa sổ test không chứng minh khả năng tổng quát qua nhiều mùa.

Phụ lục A. Chạy lại và chú giải

Các đầu ra quan trọng nằm trong repo; test lock cấm đánh giá lần hai

Lệnh chuẩn trên Windows

```
.venv\Scripts\python scripts\run_all.py
```

Sau khi có test_opened.lock.json, runner chỉ xác minh hash/split, pytest và PII; không fit hoặc chạy evaluator test. Không chạy scripts/evaluate_test_once.py lần nữa. Dashboard: .venv\Scripts\python -m streamlit run src/app/streamlit_app.py; chạy offline từ outputs/.

File bàn giao

README.md · config/split.yaml và split.lock.json · config/amendment_05_test_open.yaml · outputs/metrics/test_eval.json · docs/test_report.md · outputs/tables/product_profile.csv · docs/product_profile_top20.md · src/app/streamlit_app.py · docs/qa.md · docs/handover.md · docs/demo_script.md.

Thuật ngữ

Snapshot: bản dữ liệu có checksum. ETL: trích xuất, biến đổi, nạp. Star Schema: fact giao dịch nối dimension. Grain: mức chi tiết của một dòng dữ liệu. HMAC: băm có khóa để giả danh ID. RFM: Recency, Frequency, Monetary. Support: tỷ lệ giỏ chứa cặp. Confidence: tỷ lệ giỏ có B trong các giỏ có A. Lift: mức đồng xuất hiện so với độc lập thống kê; lift lớn hơn 1 không chứng minh nhân quả. ROC-AUC: xếp hạng dương/âm theo ngưỡng. PR-AUC: precision-recall, nhạy với lớp hiếm. Không dừng: phân phối/quan hệ thay đổi theo thời gian.

Phụ lục B. Nhật ký quyết định

Mốc và file nguồn để giải thích lựa chọn trước hội đồng

Quyết định	Nội dung
D-005	Giữ Logistic Regression C=10 làm mô hình chính; v2 là khảo sát bổ sung.
Amendment 01	Mốc mở cửa 2024-04-01; loại bán thử 2022 khỏi hành vi.
Amendment 03	Định nghĩa doanh thu ghi nhận/status 3; giữ price_adjustment; audit độ nhạy A/B.
Amendment 04	Một vòng feature v2 trên DEV; không chọn lại sau kết quả.
Amendment 05	Quà theo dòng; subset sum low-confidence; 24 combo đóng băng trước test.
D-010	Ghi rõ >T so với [T,end) thực tế; ảnh hưởng chưa xác định.
D-019/020	Cohort chưa đối soát giữ riêng; EDA DEV only, notebook fit đóng băng.
D-021/022	Diễn giải test có caveat thống nhất; chưa chạy chẩn đoán anchor trên DEV.
Cancel/refund	Không fit vì một số fold có dưới 20 dương; không thử lại.

Lần chạy evaluator đầu dừng trước khi tạo khóa do cấu hình ngày YAML; không đọc nhãn/hành vi test và không tiêu thụ lần mở. Lần thành công là lần duy nhất, khóa test_open_count=1. Log hậu mở có đúng hai loại đọc cần thiết: nhãn và hành vi; không ghi giá trị thô hoặc ID khách ra kết quả.

Tài liệu theo dõi: docs/decisions.md, docs/PROGRESS.md, docs/test_report.md, outputs/logs/test_eval_access.jsonl, config/amendment_05_test_open.yaml và config/amendment_05_test_open.lock.json. File đối chiếu tiền đã chuyển vào data/restricted/quarantine/.

Hạn nộp 2026-10-27; thời lượng chính thức và rubric chưa có trong hồ sơ.